

Prácticas de Tecnologías de Gestión de Datos

*Guillermo López Taboada (guillermo.lopez.taboada@udc.es) y Rubén F. Casal
(ruben.fcasal@udc.es)*

2019-09-10

Índice general

Prólogo	5
1 Introducción a las Tecnologías de Gestión de Datos	7
1.1 Contenidos	7
1.2 Planificación	7
1.3 Fuentes de información:	8
2 Manipulación de datos con R	11
2.1 Lectura, importación y exportación de datos	11
2.2 Manipulación de datos	14
3 Introducción al lenguaje SQL	19
3.1 Bases de Datos Relacionales	19
3.2 Sintaxis SQL	22
3.3 Conexión con bases de datos desde R	25
4 Manipulación de datos con dplyr	29
4.1 El paquete dplyr	29
4.2 Operaciones con variables (columnas)	30
4.3 Operaciones con casos (filas)	31
4.4 Resumir valores con summarise()	32
4.5 Agrupar casos con group_by()	32
4.6 Operador <i>pipe</i> %>% (tubería, redirección)	32
5 Introducción a Tecnologías NoSQL	35
5.1 Conceptos y tipos de bases de datos NoSQL (documental, columnar, clave/valor y de grafos)	35
5.2 Conexión de R a NoSQL	43
6 Tecnologías para el Tratamiento de Datos Masivos	45
6.1 Tecnologías Big Data (Hadoop, Spark, Hive, Rspark, Sparklyr)	45
6.2 Visualización y Generación de Cuadros de Mando	45
6.3 Introducción al Análisis de Datos Masivos	45
A Enlaces	47
A.1 RStudio	48

Prólogo

Este libro contiene algunas de las prácticas de la asignatura de Tecnologías de Gestión de Datos del Máster interuniversitario en Técnicas Estadísticas).

Este libro ha sido escrito en R-Markdown empleando el paquete **bookdown** y está disponible en el repositorio Github: gltaboada/tgdbook. Se puede acceder a la versión en línea a través del siguiente enlace:

<https://gltaboada.github.io/tgdbook>.

donde puede descargarse en formato pdf.

Para generar el libro (compilar) se recomendaría consultar el libro de “Escritura de libros con bookdown” en castellano.



Este obra está bajo una licencia de Creative Commons Reconocimiento-NoComercial-SinObraDerivada 4.0 Internacional (esperamos poder liberarlo bajo una licencia menos restrictiva más adelante...).

Capítulo 1

Introducción a las Tecnologías de Gestión de Datos

La información relevante de la materia está disponible en la guía docente y la ficha de la asignatura

En particular, los resultados de aprendizaje son:

- Manejar de forma autónoma y solvente el software necesario para acceder a conjuntos de datos en entornos profesionales y/o en la nube.
- Saber gestionar conjuntos de datos masivos en un entorno multidisciplinar que permita la participación en proyectos profesionales complejos que requieran el uso de técnicas estadísticas.
- Saber relacionar el software de diseño y gestión de bases de datos con el específicamente implementado para el análisis de datos.

1.1 Contenidos

1. Introducción al lenguaje SQL
 - Bases de datos relacionales
 - Sintaxis SQL
 - Conexión con bases de datos desde R
2. Introducción a tecnologías NoSQL
 - Conceptos y tipos de bases de datos NoSQL (documental, columnar, clave/valor y de grafos)
 - Conexión de R a NoSQL
3. Tecnologías para el tratamiento de datos masivos
 - Tecnologías Big Data (Hadoop, Spark, Hive, Rspark, Sparklyr)
 - Visualización y generación de cuadros de mando
 - Introducción al análisis de datos masivos.

1.2 Planificación

- Clase 1 (12/9): Seminario R: Manipulación de datos con el paquete básico de R
- Clase 2 (19/9): Tema 1: Conceptos de bases de datos
- Clase 3 (26/9): Tema 1: Introducción a SQL
- Clase 4 (3/10): Seminario dplyr

- Clase 5 (10/10): Tema 1: Ejercicios prácticos de Entidad-relación y SQL
- Clase 6 (17/10): Tema 1: Continuación de ejercicios prácticos SQL
- Clase 7 (24/10): Tema 2: Introducción a NoSQL
- Clase 8 (31/10): Tema 2: Ejercicios prácticos de NoSQL
- Clase 9 (7/11): Tema 3: Ecosistema Big Data (Hadoop, Spark)
- Clase 10 (14/11): Tema 3: Tecnologías Big Data (Rspark/sparklyr)
- Clase 11 (21/11): Seminario visualización con power BI
- Clase 12 (28/11): Seminario machine learning CESSGA/localhost
- Clase 13 (5/12): Tema 3: Introducción al análisis de datos masivos
- Clase 14 (12/12): Seminario conceptos avanzados de R
- Clase 15 (19/12): Seminario aplicaciones Big Data en investigación e industria

1.2.1 Evaluación

- **Examen** (60%): El examen de la materia evaluará los siguientes aspectos: Conceptos de la materia: Dominio de los conocimientos teóricos y operativos de la materia. Asimilación práctica de materia: Asimilación y comprensión de los conocimientos teóricos y operativos de la materia.
- **Prácticas de laboratorio** (30%): Evaluación de las prácticas de laboratorio desarrolladas por los estudiantes.
- **Trabajos tutelados** (10%): Evaluación de los trabajos tutelados desarrollados por los estudiantes.

1.2.1.1 Observaciones sobre la evaluación:

- Las prácticas de laboratorio se realizarán en grupos de 2.
- Para poder aprobar la asignatura en la primera oportunidad será necesario obtener como mínimo el 30% de la nota máxima de la suma de las prácticas de laboratorio y trabajos tutelados e, igualmente, el 30% de la nota máxima final de la Prueba mixta (examen), y tener una nota total (prácticas más trabajos tutelados más prueba mixta) igual o superior al 50% de la nota máxima.
- En la segunda oportunidad solamente se podrá recuperar la nota del examen. Las notas de prácticas y de trabajos tutelados serán las obtenidas durante el curso. Para los alumnos que utilicen la oportunidad adelantada de diciembre se utilizarán las notas de prácticas y trabajos tutelados que obtuvieran en su último curso. En esta oportunidad solo será necesario para aprobar obtener una nota total igual o superior al 50% de la nota máxima.
- Una vez que un estudiante es evaluado en una práctica de laboratorio o en un trabajo tutelado implica que será calificado. Por tanto, la calificación “No Presentado” no es posible una vez que una práctica/trabajo ha sido evaluada.

1.3 Fuentes de información:

1.3.1 Básica

- Daroczi, G. (2015). Mastering Data Analysis with R. Packt Publishing
- Grolemond, G. y Wickham, H. (2016). R for Data Science. <https://r4ds.had.co.nz/> & O'Reilly

- Silberschatz, A., Korth, H. y Sudarshan, S. (2014). Fundamentos de Bases de Datos. Mc Graw Hill
- Rubén Fernández Casal (2019). Ayuda y Recursos para el Aprendizaje de R. <https://rubenfcasal.github.io/post/ayuda-y-recursos-para-el-aprendizaje-de-r/>

1.3.2 Complementaria:

- Wes McKinney (2017). Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython. O'Reilly (2^a ed.)
- Tom White (2015). Hadoop: The Definitive Guide. O'Reilly (4^a ed.)
- Alex Holmes (2014). Hadoop in practice. Manning (2^a ed.)
- Centro de Supercomputación de Galicia (2019). Servicio de Big Data del CESGA. <https://bigdata.cesga.es/>

Capítulo 2

Manipulación de datos con R

2.1 Lectura, importación y exportación de datos

La mayoría de los estudios estadísticos requieren disponer de un conjunto de datos. Además de la introducción directa, R es capaz de importar datos externos en múltiples formatos:

- bases de datos disponibles en librerías de R
- archivos de texto en formato ASCII
- archivos en otros formatos: Excel, SPSS, ...
- bases de datos relacionales: MySQL, Oracle, ...
- formatos web: HTML, XML, JSON, ...
-

2.1.1 Acceso a datos en paquetes

R dispone de múltiples conjuntos de datos en distintos paquetes, especialmente en el paquete **datasets** que se carga por defecto al abrir R. Con el comando `data()` podemos obtener un listado de las bases de datos disponibles.

Para cargar una base de datos concreta se utiliza el comando `data(nombre)` (aunque en algunos casos se cargan automáticamente al emplearlos). Por ejemplo, `data(cars)` carga la base de datos llamada **cars** en el entorno de trabajo (`GlobalEnv`) y `?cars` muestra la ayuda correspondiente con la descripción de la base de datos.

2.1.2 Lectura de archivos de texto

En R para leer archivos de texto se suele utilizar la función `read.table()`. Supóngase, por ejemplo, que en el directorio actual está el fichero *empleados.txt*. La lectura de este fichero vendría dada por el código:

```
datos <- read.table(file = "empleados.txt", header = TRUE)
head(datos)
```

```
##   id  sexo  fechnac educ      catlab salario salini tiempemp expprev
## 1  1 Hombre  2/3/1952  15   Directivo  57000  27000      98     144
## 2  2 Hombre  5/23/1958  16 Administrativo  40200  18750      98      36
```

```
## 3 3 Mujer 7/26/1929 12 Administrativo 21450 12000 98 381
## 4 4 Mujer 4/15/1947 8 Administrativo 21900 13200 98 190
## 5 5 Hombre 2/9/1955 15 Administrativo 45000 21000 98 138
## 6 6 Hombre 8/22/1958 15 Administrativo 32100 13500 98 67
##  minoria
## 1 No
## 2 No
## 3 No
## 4 No
## 5 No
## 6 No
```

Si el fichero estuviese en el directorio `c:\datos` bastaría con especificar `file = "c:/datos/empleados.txt"`. Nótese también que para la lectura del fichero anterior se ha establecido el argumento `header=TRUE` para indicar que la primera línea del fichero contiene los nombres de las variables.

Los argumentos utilizados habitualmente para esta función son:

- **header**: indica si el fichero tiene cabecera (`header=TRUE`) o no (`header=FALSE`). Por defecto toma el valor `header=FALSE`.
- **sep**: carácter separador de columnas que por defecto es un espacio en blanco (`sep=" "`). Otras opciones serían: `sep=","` si el separador es un “;”, `sep="*"` si el separador es un “*”, etc.
- **dec**: carácter utilizado en el fichero para los números decimales. Por defecto se establece `dec = "."`. Si los decimales vienen dados por “,” se utiliza `dec = ","`.

Resumiendo, los (principales) argumentos por defecto de la función `read.table` son los que se muestran en la siguiente línea:

```
read.table(file, header = FALSE, sep = " ", dec = ".")
```

Para más detalles sobre esta función véase `help(read.table)`.

Están disponibles otras funciones con valores por defecto de los parámetros adecuados para otras situaciones. Por ejemplo, para ficheros separados por tabuladores se puede utilizar `read.delim()` o `read.delim2()`:

```
read.delim(file, header = TRUE, sep = "\t", dec = ".")
read.delim2(file, header = TRUE, sep = "\t", dec = ",")
```

2.1.3 Importación desde SPSS

El programa R permite lectura de ficheros de datos en formato SPSS (extensión `.sav`) sin necesidad de tener instalado dicho programa en el ordenador. Para ello se necesita:

- cargar la librería `foreign`
- utilizar la función `read.spss`

Por ejemplo:

```
library(foreign)
datos <- read.spss(file = "Employee data.sav", to.data.frame = TRUE)
```

```
## re-encoding from CP1252
```

```
head(datos)
```

```
##  id  sexo  fechnac educ  catlab salario salini tiempemp
## 1  1 Hombre 11654150400  15  Directivo  57000 27000 98
## 2  2 Hombre 11852956800  16 Administrativo  40200 18750 98
```

```
## 3 3 Mujer 10943337600 12 Administrativo 21450 12000 98
## 4 4 Mujer 11502518400 8 Administrativo 21900 13200 98
## 5 5 Hombre 11749363200 15 Administrativo 45000 21000 98
## 6 6 Hombre 11860819200 15 Administrativo 32100 13500 98
## expprev minoria
## 1 144 No
## 2 36 No
## 3 381 No
## 4 190 No
## 5 138 No
## 6 67 No
```

Nota: Si hay fechas, puede ser recomendable emplear la función `spss.get()` del paquete `Hmisc`.

2.1.4 Importación desde Excel

Se pueden leer fichero de Excel (con extensión *.xls*) utilizando por ejemplo funciones de las librerías `openxlsx`, `XLConnect` o `RODBC`. Sin embargo, puede ser recomendable exportar los datos desde Excel a un archivo de texto separado por tabuladores (extensión *.csv*).

Por ejemplo, supongamos que queremos leer el fichero *coches.xls*:

- Desde Excel se selecciona el menú **Archivo -> Guardar como -> Guardar como** y en **Tipo** se escoge la opción de archivo CSV. De esta forma se guardarán los datos en el archivo *coches.csv*.
- El fichero *coches.csv* es un fichero de texto plano (se puede editar con Notepad), con cabecera, las columnas separadas por “;”, y siendo “.” el carácter decimal.
- Por lo tanto, la lectura de este fichero se puede hacer con:

```
datos <- read.table("coches.csv", header = TRUE, sep = ";", dec = ",")
```

Otra posibilidad es utilizar la función `read.csv2`, que es una adaptación de la función general `read.table` con las siguientes opciones:

```
read.csv2(file, header = TRUE, sep = ";", dec = ",")
```

Por lo tanto, la lectura del fichero *coches.csv* se puede hacer de modo más directo con:

```
datos <- read.csv2("coches.csv")
```

2.1.5 Exportación de datos

Es evidente que además de la lectura e importación de datos también será de gran interés la exportación de datos para que puedan leerlos con otros programas. Para ello, es de gran utilidad la función `write.table`. Esta función es similar, pero funcionando en sentido inverso, a la ya vista `read.table`.

Veamos un ejemplo:

```
tipo <- c("A", "B", "C")
longitud <- c(120.34, 99.45, 115.67)
datos <- data.frame(tipo, longitud)
datos
```

```
## tipo longitud
## 1 A 120.34
## 2 B 99.45
## 3 C 115.67
```

Para guardar el data.frame `datos` en un fichero de texto se puede utilizar:

```
write.table(datos, file = "datos.txt")
```

Otra posibilidad es utilizar la función:

```
write.csv2(datos, file = "datos.csv")
```

que dará lugar al fichero `datos.csv` importable directamente desde Excel.

2.2 Manipulación de datos

Una vez cargada una (o varias) bases de datos hay una series de operaciones que serán de interés para el tratamiento de datos:

- Operaciones con variables:
 - creación
 - recodificación (e.g. categorización)
 - ...
- Operaciones con casos:
 - ordenación
 - filtrado de datos
 - ...

A continuación se tratan las operaciones más básicas.

2.2.1 Operaciones con variables

2.2.1.1 Creación (y eliminación) de variables

Consideremos de nuevo la base de datos `cars` incluida en el paquete `datasets`:

```
data(cars)
head(cars)
```

```
##   speed dist
## 1     4    2
## 2     4   10
## 3     7    4
## 4     7   22
## 5     8   16
## 6     9   10
```

Utilizando el comando `help(cars)` se obtiene que `cars` es un data.frame con 50 observaciones y dos variables:

- `speed`: Velocidad (millas por hora)
- `dist`: tiempo hasta detenerse (pies)

Recordemos que, para acceder a la variable `speed` se puede hacer directamente con su nombre o bien utilizando notación “matricial”.

```
cars$speed
```

```
## [1]  4  4  7  7  8  9 10 10 10 11 11 12 12 12 12 13 13 13 13 14 14 14 14
## [24] 15 15 15 16 16 17 17 17 18 18 18 18 19 19 19 20 20 20 20 20 22 23 24
## [47] 24 24 24 25
```

```
cars[, 1] # Equivalente
```

```
## [1] 4 4 7 7 8 9 10 10 10 11 11 12 12 12 12 13 13 13 13 14 14 14 14
## [24] 15 15 15 16 16 17 17 17 18 18 18 18 19 19 19 20 20 20 20 20 22 23 24
## [47] 24 24 24 25
```

Supongamos ahora que queremos transformar la variable original `speed` (millas por hora) en una nueva variable `velocidad` (kilómetros por hora) y añadir esta nueva variable al `data.frame` `cars`. La transformación que permite pasar millas a kilómetros es `kilómetros=millas/0.62137` que en R se hace directamente con:

```
cars$speed/0.62137
```

Finalmente, incluimos la nueva variable que llamaremos `velocidad` en `cars`:

```
cars$velocidad <- cars$speed / 0.62137
head(cars)
```

```
##   speed dist velocidad
## 1     4    2  6.437388
## 2     4   10  6.437388
## 3     7    4 11.265430
## 4     7   22 11.265430
## 5     8   16 12.874777
## 6     9   10 14.484124
```

También transformaremos la variable `dist` (en pies) en una nueva variable `distancia` (en metros). Ahora la transformación deseada es `metros=pies/3.2808`:

```
cars$distancia <- cars$dis / 3.2808
head(cars)
```

```
##   speed dist velocidad distancia
## 1     4    2  6.437388 0.6096074
## 2     4   10  6.437388 3.0480371
## 3     7    4 11.265430 1.2192148
## 4     7   22 11.265430 6.7056815
## 5     8   16 12.874777 4.8768593
## 6     9   10 14.484124 3.0480371
```

Ahora, eliminaremos las variables originales `speed` y `dist`, y guardaremos el `data.frame` resultante con el nombre `coches`. En primer lugar, veamos varias formas de acceder a las variables de interés:

```
cars[, c(3, 4)]
cars[, c("velocidad", "distancia")]
cars[, -c(1, 2)]
```

Utilizando alguna de las opciones anteriores se obtiene el `data.frame` deseado:

```
coches <- cars[, c("velocidad", "distancia")]
head(coches)
```

```
##   velocidad distancia
## 1  6.437388 0.6096074
## 2  6.437388 3.0480371
## 3 11.265430 1.2192148
## 4 11.265430 6.7056815
## 5 12.874777 4.8768593
## 6 14.484124 3.0480371
```

Finalmente los datos anteriores podrían ser guardados en un fichero exportable a Excel con el siguiente comando:

```
write.csv2(coches, file = "coches.csv")
```

2.2.2 Operaciones con casos

2.2.2.1 Ordenación

Continuemos con el data.frame `cars`. Se puede comprobar que los datos disponibles están ordenados por los valores de `speed`. A continuación haremos la ordenación utilizando los valores de `dist`. Para ello utilizaremos el conocido como vector de índices de ordenación. Este vector establece el orden en que tienen que ser elegidos los elementos para obtener la ordenación deseada. Veamos un ejemplo sencillo:

```
x <- c(2.5, 4.3, 1.2, 3.1, 5.0) # valores originales
ii <- order(x)
ii # vector de ordenación
```

```
## [1] 3 1 4 2 5
```

```
x[ii] # valores ordenados
```

```
## [1] 1.2 2.5 3.1 4.3 5.0
```

En el caso de vectores, el procedimiento anterior se podría hacer directamente con:

```
sort(x)
```

Sin embargo, para ordenar data.frames será necesario la utilización del vector de índices de ordenación. A continuación, los datos de `cars` ordenados por `dist`:

```
ii <- order(cars$dist) # Vector de índices de ordenación
cars2 <- cars[ii, ]    # Datos ordenados por dist
head(cars2)
```

```
##   speed dist velocidad distancia
## 1     4    2  6.437388 0.6096074
## 3     7    4 11.265430 1.2192148
## 2     4   10  6.437388 3.0480371
## 6     9   10 14.484124 3.0480371
## 12    12   14 19.312165 4.2672519
## 5     8   16 12.874777 4.8768593
```

2.2.2.2 Filtrado

El filtrado de datos consiste en elegir una submuestra que cumpla determinadas condiciones. Para ello se puede utilizar la función `subset`. A continuación se muestran un par de ejemplos:

```
subset(cars, dist > 85) # datos con dis>85
```

```
##   speed dist velocidad distancia
## 47    24   92  38.62433 28.04194
## 48    24   93  38.62433 28.34674
## 49    24  120  38.62433 36.57644
```

```
subset(cars, speed > 10 & speed < 15 & dist > 45) # speed en (10,15) y dist>45
```



```
##      speed dist velocidad distancia
## 19      13   46  20.92151  14.02097
## 22      14   60  22.53086  18.28822
## 23      14   80  22.53086  24.38430
```

También se pueden hacer el filtrado empleando directamente los correspondientes vectores de índices:

```
ii <- cars$dist > 85
cars[ii, ]      # dis>85
```

```
##      speed dist velocidad distancia
## 47      24   92  38.62433  28.04194
## 48      24   93  38.62433  28.34674
## 49      24  120  38.62433  36.57644
```

```
ii <- cars$speed > 10 & cars$speed < 15 & cars$dist > 45
cars[ii, ]      # speed en (10,15) y dist>45
```

```
##      speed dist velocidad distancia
## 19      13   46  20.92151  14.02097
## 22      14   60  22.53086  18.28822
## 23      14   80  22.53086  24.38430
```


Capítulo 3

Introducción al lenguaje SQL

Los sistemas de información gestionan repositorios de información en múltiples formatos, siendo el más popular las bases de datos relacionales a las que se accede mediante SQL (Structured Query Language)

3.1 Bases de Datos Relacionales

3.1.1 Definiciones

- **Dominio:** contexto (organización, empresa, evento...) objeto de gestión de la información.
 - **Dato:** hecho con significado implícito, registrable, relevante en un determinado dominio.
 - **Base de datos:** colección de datos de un determinado dominio relacionados entre sí, organizados de forma que sea posible manipularlos y recuperarlos de forma eficiente.
 - Sistema de Gestión de Bases de Datos (**SGBD**) (en inglés **RDBMS**, Relational Database Management System): software que permite a los usuarios crear y manipular bases de datos mediante operaciones CRUD:
 - Crear / Insertar Datos (Create)
 - Consultar / Leer (Read)
 - Actualizar / Modificar (Update)
 - Eliminar (Delete)
-
- **Modelo de datos:** abstracción conceptual que propone una manera de organizar y manipular los datos. Definido mediante:
 - Estructura: elementos para organizar datos
 - Integridad: reglas para relaciones los elementos
 - Manipulación: operaciones sobre los datos adaptadas a la estructura y reglas
 - Modelo de datos conceptual **Entidad Relación** (entidades, relaciones, atributos)
 - Modelo de datos lógico o de representación (**modelo relacional** de Codd)
 - Datos en relaciones (tablas)
 - Base matemática formal
 - Flexible
 - Modelo de datos físico (tal y como se almacenan los datos)

Una fila de la tabla (relación) es una tupla y una columna un atributo (ver Figura 3.1).

(ver Figura 3.1)

(ver Figura 3.1)

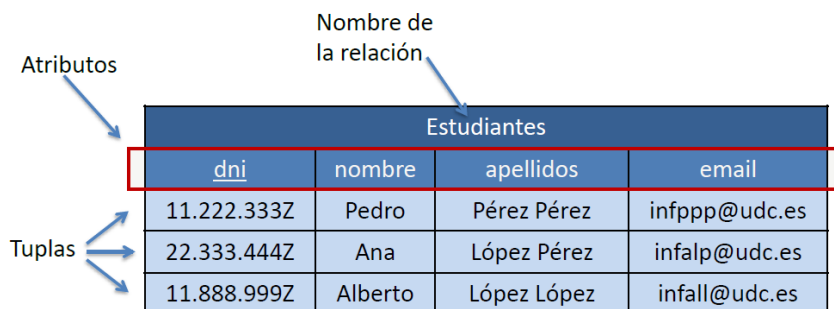


Figura 3.1: Esquema de una relación.

Una base de datos es un conjunto de tablas (al menos una).

La tabla no es una relación porque la relación es un conjunto sin orden y una tabla puede tener filas repetidas y tiene orden.

-
- **Esquema:** estructura de la base de datos
 - **Estado:** contenido de la base de datos
 - Restricción de **integridad:** regla que debe cumplir la información registrada en la base de datos para garantizar la integridad de la información.

Cualquier Base de Datos basada en el modelo relacional ha de cumplir como mínimo estas restricciones (además de las propias del dominio):

- Restricción de dominio: el valor de cada atributo debe de ser único (teléfono, no valor único), no descomponible (nombre completo descomponible en nombre y apellidos, domicilio en calle, CP, localidad, etc...)
 - Una relación es un conjunto de tuplas, por tanto todas las tuplas son distintas.
 - Una **superclave** es un subconjunto de atributos tal que no existen dos tuplas con la misma superclave.
- Ejercicio. En la relación Empleado(dni, nombre, apellidos, email) ¿cuántas superclaves existen?
- Una **clave candidata** es una superclave mínima (superclave mínima es la clave a la que no se le puede eliminar un atributo).

¿Cuántas claves candidatas hay en el ejemplo anterior?

- **Clave primaria** es la clave candidata que elegimos que identificar de forma unívoca las tuplas de una relación. Restricción de integridad de entidad: Ningún valor de la clave primaria puede ser un valor nulo.
- **Clave foránea** es un conjunto de atributos de una relación R_1 que, para cada tupla, identifican a otra tupla de una relación R_2 con la que está relacionada. La Restricción de integridad referencial nos dice que la clave foránea ha de corresponderse con la clave primaria de R_2, y si la clave foránea no es nula ha de refer a una tupla en R_2.

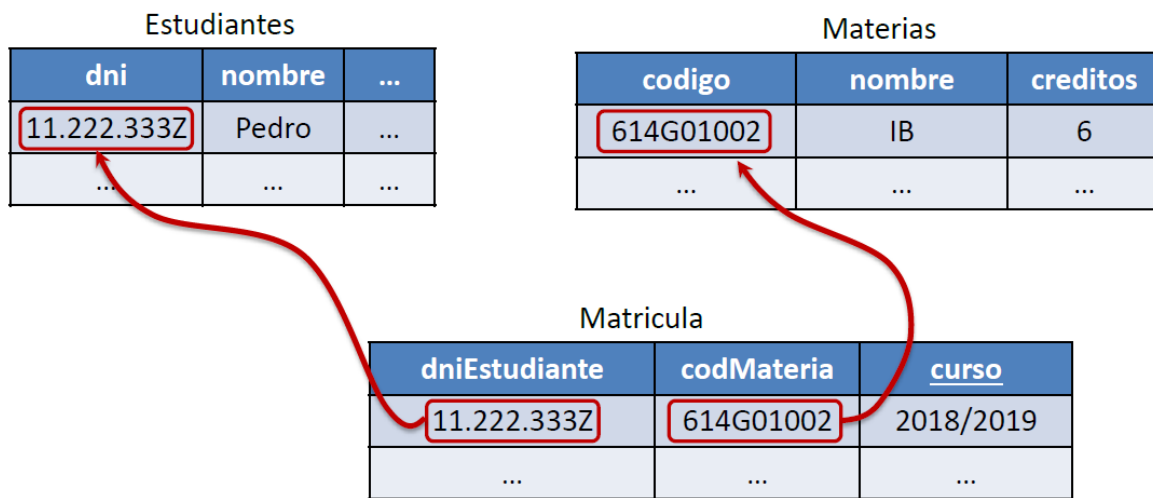


Figura 3.2:





Figura 3.3:



La foránea *despacho* toma valor nulo en esta tupla
(El docente no tiene todavía despacho asignado)
ES CORRECTO Y NO VIOLA LA RESTRICCIÓN

Figura 3.4:

Si borramos/actualizamos un valor de clave foránea podemos: (a) prohibir el cambio, o (b) poner a nulo la clave foránea (borrado) o propagar el cambio (modificación).

- Ventajas de SGBD:
 - Administración centralizada de los datos (por un administrador en un servidor/plataforma central que evita la información en silos -redundante/inconsistente)
 - Desacoplado del almacenamiento físico de los datos (no es necesario conocerlo)
 - Simplicidad de acceso (ODBC + SQL, lenguaje declarativo)
 - Control de integridad (restricciones genéricas, integridad de entidad y referencial, de dominio, y las del dominio en software)
 - Control de acceso concurrente (evita inconsistencia)
 - Seguridad (autenticación, roles de acceso)
 - Recuperación ante fallos (backup, logs y transacciones -rollback-)

3.2 Sintaxis SQL

A continuación 27 cláusulas SQL básicas

3.2.1 Extracción SQL (11 statements)

```
SELECT column1, column2....columnN
FROM table_name;

SELECT DISTINCT column1, column2....columnN
FROM table_name;

SELECT column1, column2....columnN
FROM table_name
WHERE CONDITION;
```

```

SELECT column1, column2....columnN
FROM   table_name
WHERE  CONDITION-1 {AND|OR} CONDITION-2;

SELECT column1, column2....columnN
FROM   table_name
WHERE  column_name IN (val-1, val-2,...val-N);

SELECT column1, column2....columnN
FROM   table_name
WHERE  column_name BETWEEN val-1 AND val-2;

SELECT column1, column2....columnN
FROM   table_name
WHERE  column_name LIKE { PATTERN };

SELECT column1, column2....columnN
FROM   table_name
WHERE  CONDITION
ORDER BY column_name {ASC|DESC};

SELECT SUM(column_name)
FROM   table_name
WHERE  CONDITION
GROUP BY column_name;

SELECT COUNT(column_name)
FROM   table_name
WHERE  CONDITION;

SELECT SUM(column_name)
FROM   table_name
WHERE  CONDITION
GROUP BY column_name
HAVING (arithmetic function condition);

```

3.2.2 Crear/Actualizar/Borrar tablas SQL (8 statements)

```

CREATE TABLE table_name(
column1 datatype,
column2 datatype,
column3 datatype,
.....
columnN datatype,
PRIMARY KEY( one or more columns )
);

DROP TABLE table_name;

CREATE UNIQUE INDEX index_name
ON table_name ( column1, column2,...columnN);

```

```
ALTER TABLE table_name
DROP INDEX index_name;

DESC table_name;

TRUNCATE TABLE table_name;

ALTER TABLE table_name {ADD|DROP|MODIFY} column_name {data_type};

ALTER TABLE table_name RENAME TO new_table_name;
```

3.2.3 Añadir/Actualizar/Borrar tuplas en SQL (3 statements)

```
INSERT INTO table_name( column1, column2....columnN)
VALUES ( value1, value2....valueN);

UPDATE table_name
SET column1 = value1, column2 = value2....columnN=valueN
[ WHERE CONDITION ];

DELETE FROM table_name
WHERE {CONDITION};
```

3.2.4 Gestión Bases de Datos (5 statements)

```
CREATE DATABASE database_name;

DROP DATABASE database_name;

USE database_name;

COMMIT;

ROLLBACK;
```

3.2.5 Ejemplos de consultas SQL

```
SELECT Nombre, Apellido1, Apellido2, Municipio, Provincia
FROM Cliente
WHERE Municipio = 'Lugo'
ORDER BY Apellido1

INSERT Proveedor(Nombre, PersonaContacto, Ciudad, País)
VALUES ('Café Candelas', 'Ivana Candelas', 'Lugo', 'España')

UPDATE Pedidos
SET Cantidad = 2
WHERE IdProducto = 963
```



```
DELETE Cliente
WHERE Email = 'alexandregb@gmail.com'
```

3.3 Conexión con bases de datos desde R

3.3.1 Introducción a SQL en R

SQL se usa para manipular datos dentro de una base de datos. Si la base de datos no es muy grande se puede cargar toda en un `data.frame`. No obstante, por escalabilidad y offloading de la carga de trabajo al servidor SGBD utilizaremos SQL.

Existen varios SGBD (SQLite, Microsoft SQL Server, PostgreSQL, etc) los cuales comparten el soporte de SQL (en concreto ANSI SQL) aunque cada gestor extiende SQL de formas sutiles buscando minar cierta portabilidad de código (*vendor-locking*). En efecto, un código SQL desarrollado para SQLite es probable que falle con MySQL aunque tras aplicar ligeras modificaciones ya funcionará. Asimismo el mecanismo de conexión, configuración, rendimiento y operación suele diferir entre SGBD.

A continuación se lista una serie de paquetes utilizados en el acceso a los datos, lo que suele ser el principal esfuerzo a realizar cuando se trabaja con SGBD:

- DBI
- RODBC
- dbConnect
- RSQLite
- RMySQL
- RPostgreSQL

3.3.2 El paquete sqldf

A continuación se presenta una serie de ejercicios con la sintaxis de SQL operando sobre un `data.frame` con el paquete `sqldf`. Esto inicialmente no incluye los detalles de conectarse a un SGBD, ni modificar los datos, solamente el uso de SQL para extraer datos con el objetivo de ser analizados en R.

```
library(sqldf)
```

```
sqldf('SELECT age, circumference FROM Orange WHERE Tree = 1 ORDER BY circumference ASC')
```

```
##      age circumference
## 1   118             30
## 2   484             58
## 3   664             87
## 4  1004            115
## 5  1231            120
## 6  1372            142
## 7  1582            145
```

3.3.3 SQL Queries

El comando inicial es `SELECT`. SQL no es case-sensitive, por lo que esto va a funcionar:

```
sqldf("SELECT * FROM iris")
sqldf("select * from iris")
```

pero lo siguiente no va a funcionar (a menos que tengamos un objeto IRIS:

```
sqldf("SELECT * FROM IRIS")
```

La sintaxis básica de SELECT es:

```
SELECT variable1, variable2 FROM data
```

3.3.3.1 Asterisco/Wildcard

Lo extrae todo

```
bod2 <- sqldf('SELECT * FROM BOD')
```

3.3.3.2 Limit

Limita el número de resultados

```
sqldf('SELECT * FROM iris LIMIT 5')
```

```
##   Sepal.Length Sepal.Width Petal.Length Petal.Width Species
## 1         5.1         3.5         1.4         0.2   setosa
## 2         4.9         3.0         1.4         0.2   setosa
## 3         4.7         3.2         1.3         0.2   setosa
## 4         4.6         3.1         1.5         0.2   setosa
## 5         5.0         3.6         1.4         0.2   setosa
```

3.3.3.3 Order By

Ordena las variables

```
ORDER BY var1 {ASC/DESC}, var2 {ASC/DESC}
```

```
sqldf("SELECT * FROM Orange ORDER BY age ASC, circumference DESC LIMIT 5")
```

```
##   Tree age circumference
## 1     2 118           33
## 2     4 118           32
## 3     1 118           30
## 4     3 118           30
## 5     5 118           30
```

3.3.3.4 Where

Sentencias condicionales, donde se puede incorporar operadores lógicos AND y OR, expresando el orden de evaluación con paréntesis en caso de ser necesario.

```
sqldf('SELECT demand FROM BOD WHERE Time < 3')
```

```
##   demand
## 1     8.3
## 2    10.3
```

```
sqldf('SELECT * FROM rock WHERE (peri > 5000 AND shape < .05) OR perm > 1000')
```

```
##   area      peri      shape perm
## 1 5048    941.543 0.328641 1300
## 2 1016    308.642 0.230081 1300
## 3 5605   1145.690 0.464125 1300
## 4 8793   2280.490 0.420477 1300
```

Y extendiendo su uso con IN o LIKE (es último sólo con %), pudiendo aplicárseles el NOT:

```
sqldf('SELECT * FROM BOD WHERE Time IN (1,7)')
```

```
##   Time demand
## 1      1      8.3
## 2      7     19.8
```

```
sqldf('SELECT * FROM BOD WHERE Time NOT IN (1,7)')
```

```
##   Time demand
## 1      2     10.3
## 2      3     19.0
## 3      4     16.0
## 4      5     15.6
```

```
sqldf('SELECT * FROM chickwts WHERE feed LIKE "%bean" LIMIT 5')
```

```
##   weight      feed
## 1     179 horsebean
## 2     160 horsebean
## 3     136 horsebean
## 4     227 horsebean
## 5     217 horsebean
```

```
sqldf('SELECT * FROM chickwts WHERE feed NOT LIKE "%bean" LIMIT 5')
```

```
##   weight      feed
## 1     309 linseed
## 2     229 linseed
## 3     181 linseed
## 4     141 linseed
## 5     260 linseed
```


Capítulo 4

Manipulación de datos con dplyr

4.1 El paquete dplyr

```
library(dplyr)
```

dplyr¹ permite sustituir funciones base de R (como `split()`, `subset()`, `apply()`, `sapply()`, `lapply()`, `tapply()` y `aggregate()`) mediante una “gramática” más sencilla para la manipulación de datos:

- `select()` seleccionar variables/columnas (también `rename()`).
- `mutate()` crear variables/columnas (también `transmute()`).
- `filter()` seleccionar casos/filas (también `slice()`).
- `arrange()` ordenar o organizar casos/filas.
- `summarise()` resumir valores.
- `group_by()` permite operaciones por grupo empleando el concepto “dividir-aplicar-combinar” (`ungroup()` elimina el agrupamiento).

Puede trabajar con conjuntos de datos en distintos formatos:

- `data.frame`, `data.table`, `tibble`, ...
- bases de datos relacionales (lenguaje SQL), ...
- bases de datos *Hadoop* (paquete `plymr`).

En lugar de operar sobre vectores como las funciones base, opera sobre objetos de este tipo (en este capítulo nos centraremos en `data.frame`).

El tipo de objeto que emplea por defecto **dplyr** para almacenar datos es el `tibble`, una modificación del `data.frame` para facilitar su manejo. Para más detalles se puede ver el Capítulo 10 del libro *R for Data Science*.

4.1.1 Datos de ejemplo

El fichero *empleados.RData* contiene datos de empleados de un banco. Supongamos por ejemplo que estamos interesados en estudiar si hay discriminación por cuestión de sexo o raza.

¹`dplyr` es una mejora del paquete `plyr`, para una comparación ver p.e. <https://blog.rstudio.com/2014/01/17/introducing-dplyr>

4.2 Operaciones con variables (columnas)

4.2.1 Seleccionar variables con select()

```
emplea2 <- select(empleados, id, sexo, minoria, tiempemp, salini, salario)
head(emplea2)
```

```
##   id  sexo minoria tiempemp salini salario
## 1  1 Hombre      No      98  27000  57000
## 2  2 Hombre      No      98  18750  40200
## 3  3 Mujer       No      98  12000  21450
## 4  4 Mujer       No      98  13200  21900
## 5  5 Hombre      No      98  21000  45000
## 6  6 Hombre      No      98  13500  32100
```

Se puede cambiar el nombre (ver también *?rename()*)

```
head(select(empleados, sexo, noblanca = minoria, salario))
```

```
##      sexo noblanca salario
## 1 Hombre      No  57000
## 2 Hombre      No  40200
## 3  Mujer      No  21450
## 4  Mujer      No  21900
## 5 Hombre      No  45000
## 6 Hombre      No  32100
```

Se pueden emplear los nombres de variables como índices:

```
head(select(empleados, sexo:salario))
```

```
##      sexo   fechnac educ      catlab salario
## 1 Hombre 1952-02-03  15      Directivo  57000
## 2 Hombre 1958-05-23  16 Administrativo  40200
## 3  Mujer 1929-07-26  12 Administrativo  21450
## 4  Mujer 1947-04-15   8 Administrativo  21900
## 5 Hombre 1955-02-09  15 Administrativo  45000
## 6 Hombre 1958-08-22  15 Administrativo  32100
```

```
head(select(empleados, -(sexo:salario)))
```

```
##   id salini tiempemp expprev minoria  sexoraza
## 1  1 27000      98    144      No Blanca varón
## 2  2 18750      98     36      No Blanca varón
## 3  3 12000      98    381      No Blanca mujer
## 4  4 13200      98    190      No Blanca mujer
## 5  5 21000      98    138      No Blanca varón
## 6  6 13500      98     67      No Blanca varón
```

Hay opciones para considerar distintos criterios: *starts_with()*, *ends_with()*, *contains()*, *matches()*, *one_of()* (ver *?select*).

```
head(select(empleados, starts_with("s")))

```

```
##      sexo salario salini  sexoraza
## 1 Hombre  57000  27000 Blanca varón
## 2 Hombre  40200  18750 Blanca varón
```

```
## 3  Mujer    21450  12000 Blanca mujer
## 4  Mujer    21900  13200 Blanca mujer
## 5  Hombre   45000  21000 Blanca varón
## 6  Hombre   32100  13500 Blanca varón
```

4.2.2 Generar nuevas variables con mutate()

```
head(mutate(emplea2, incsal = salario - salini, tsal = incsal/tiempemp ))
```

```
##   id  sexo minoria tiempemp salini salario incsal      tsal
## 1  1 Hombre      No       98  27000  57000  30000 306.12245
## 2  2 Hombre      No       98  18750  40200  21450 218.87755
## 3  3 Mujer      No       98  12000  21450   9450  96.42857
## 4  4 Mujer      No       98  13200  21900   8700  88.77551
## 5  5 Hombre      No       98  21000  45000  24000 244.89796
## 6  6 Hombre      No       98  13500  32100  18600 189.79592
```

4.3 Operaciones con casos (filas)

4.3.1 Seleccionar casos con filter()

```
head(filter(emplea2, sexo == "Mujer", minoria == "Si"))
```

```
##   id  sexo minoria tiempemp salini salario
## 1 14 Mujer      Si       98  16800  35100
## 2 23 Mujer      Si       97  11100  24000
## 3 24 Mujer      Si       97   9000  16950
## 4 25 Mujer      Si       97   9000  21150
## 5 40 Mujer      Si       96   9000  19200
## 6 41 Mujer      Si       96  11550  23550
```

4.3.2 Organizar casos con arrange()

```
head(arrange(emplea2, salario))
```

```
##   id  sexo minoria tiempemp salini salario
## 1 378 Mujer      No       70  10200  15750
## 2 338 Mujer      No       74  10200  15900
## 3  90 Mujer      No       92   9750  16200
## 4 224 Mujer      No       82  10200  16200
## 5 411 Mujer      No       68  10200  16200
## 6 448 Mujer      Si       66  10200  16350
```

```
head(arrange(emplea2, desc(salini), salario))
```

```
##   id  sexo minoria tiempemp salini salario
## 1  29 Hombre      No       96  79980  135000
## 2 343 Hombre      No       73  60000  103500
## 3 205 Hombre      No       83  52500   66750
## 4 160 Hombre      No       86  47490   66000
```

```
## 5 431 Hombre      No      66 45000 86250
## 6  32 Hombre      No      96 45000 110625
```

4.4 Resumir valores con summarise()

```
summarise(empleados, sal.med = mean(salario), n = n())
```

```
##      sal.med      n
## 1 34419.57 474
```

4.5 Agrupar casos con group_by()

```
summarise(group_by(empleados, sexo, minoria), sal.med = mean(salario), n = n())
```

```
## # A tibble: 4 x 4
## # Groups:   sexo [2]
##   sexo  minoria sal.med      n
##   <fct> <fct>    <dbl> <int>
## 1 Hombre No      44475.   194
## 2 Hombre Si      32246.    64
## 3 Mujer  No      26707.   176
## 4 Mujer  Si      23062.    40
```

4.6 Operador *pipe* %>% (tubería, redirección)

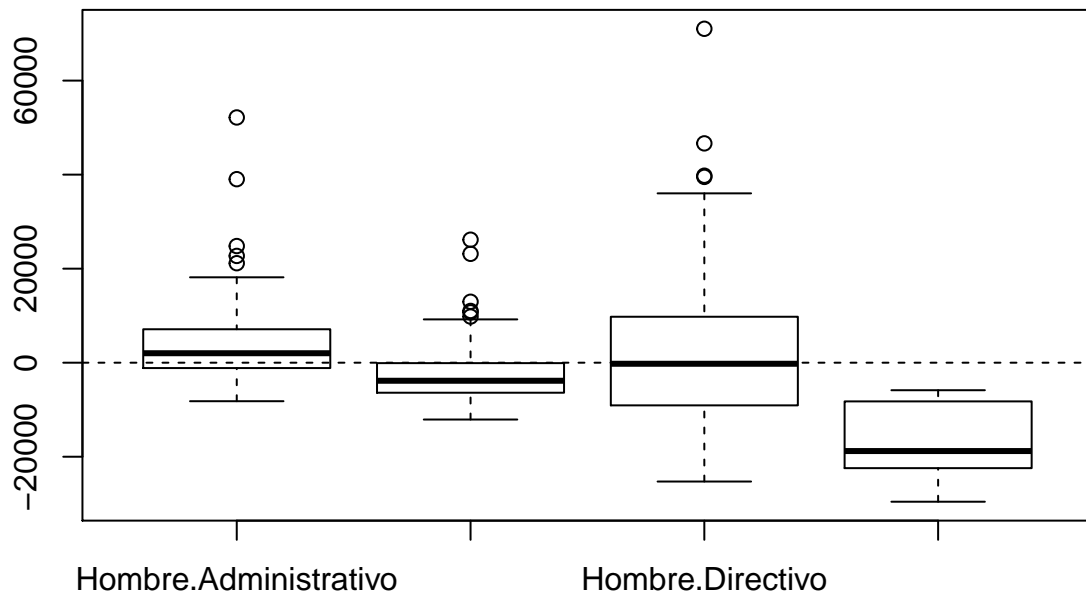
Este operador le permite canalizar la salida de una función a la entrada de otra función. `segundo(primer(datos))` se traduce en `datos %>% primero %>% segundo` (lectura de funciones de izquierda a derecha).

Ejemplos:

```
empleados %>% filter(catlab == "Directivo") %>%
  group_by(sexo, minoria) %>%
  summarise(sal.med = mean(salario), n = n())
```

```
## # A tibble: 3 x 4
## # Groups:   sexo [2]
##   sexo  minoria sal.med      n
##   <fct> <fct>    <dbl> <int>
## 1 Hombre No      65684.    70
## 2 Hombre Si      76038.     4
## 3 Mujer  No      47214.    10
```

```
empleados %>% select(sexo, catlab, salario) %>%
  filter(catlab != "Seguridad") %>%
  group_by(catlab) %>%
  mutate(saldif = salario - mean(salario)) %>%
  ungroup() %>%
  boxplot(saldif ~ sexo*droplevels(catlab), data = .)
abline(h = 0, lty = 2)
```

Para mas información sobre *dplyr* ver por ejemplo la ‘vignette’ del paquete: [Introduction to dplyr](#).

Capítulo 5

Introducción a Tecnologías NoSQL

5.1 Conceptos y tipos de bases de datos NoSQL (documental, columnar, clave/valor y de grafos)

NoSQL - “Not Only SQL” - es una nueva categoría de bases de datos no-relacionales y altamente distribuidas.

Las bases de datos NoSQL nacen de la necesidad de:

- Simplicidad en los diseños
- Escalado horizontal
- Mayor control en la disponibilidad

Pero cuidado, en muchos escenarios las BBDD relacionales siguen siendo la mejor opción.

5.1.1 Características de las bases de datos NoSQL

- Libre de esquemas – no se diseñan las tablas y relaciones por adelantado, además de permitir la migración del esquema.
- Proporcionan replicación a través de escalado horizontal.
- Este escalado horizontal se traduce en arquitectura distribuida
- Generalmente ofrecen consistencia débil
- Hacen uso de estructuras de datos sencillas, normalmente pares clave/valor a bajo nivel
- Suelen tener un sistema de consultas propio (o SQL-like)
- Siguen el modelo BASE (*Basic Availability, Soft state, Eventual consistency*) en lugar de ACID (*Atomicity, Consistency, Isolation, Durability*)

El modelo BASE consiste en:

- Basic Availability – el sistema garantiza disponibilidad, en términos del teorema CAP.
- Soft state – el estado del sistema puede cambiar a lo largo del tiempo, incluso sin entrada. Esto es provocado por el modelo de consistencia eventual.
- Eventual consistency – el sistema alcanzará un estado consistente con el tiempo, siempre y cuando no reciba entrada durante ese tiempo.

5.1.1.1 Teorema CAP

Es imposible para un sistema de cómputo distribuido garantizar simultáneamente:




Figura 5.1:

- Consistency – Todos los nodos ven los mismos datos al mismo tiempo
- Availability – Toda petición obtiene una respuesta en caso tanto de éxito como fallo
- Partition Tolerance – El sistema seguirá funcionando ante pérdidas arbitrarias de información o fallos parciales

Las razones para escoger NoSQL son:

- Analítica
- Gran cantidad de escrituras, análisis en bloque
- Escalabilidad
- Tan fácil como añadir un nuevo nodo a la red, bajo coste.
- Redundancia
- Están diseñadas teniendo en cuenta la redundancia
- Rápido desarrollo
- Al ser schema-less o schema on-read son más flexibles que schema on-write
- Flexibilidad en el almacenamiento de datos
- Almacenan todo tipo de datos: texto, imágenes, BLOBs
- Gran rendimiento en consultas sobre datos que no implican relaciones jerárquicas
- Gran rendimiento sobre BBDD desnormalizadas
- Tamaño

Columnar:

1	Things	A	foo	B	bar	C	baz
2	Things	C	bam	E	coh	People	A Emmanuel
3	Languages	A	C	B	java	C	Ceylon

Documental:

```
{ "user": {
  "id": "124",
  "name": "Emmanuel",
  "addresses": [
    { "city": "Paris", "country": "France" },
    { "city": "Atlanta", "country": "USA" }
  ]
}
```

Key-value:

key	value
123	Address@23
126	"Booya"

Graph:




Figura 5.2:

- El tamaño del esquema de datos es demasiado grande
- Muchos datos temporales fuera de almacén principal

Razones para NO escoger NoSQL: * Consistencia y Disponibilidad de los datos son críticas * Relaciones entre datos son importantes + E.g. joins numerosos y/o importantes * En general, cuando el modelo ACID encaja mejor

5.1.2 Tipos de Bases de Datos NoSQL

5.1.3 MongoDB: NoSQL documental

5.1.4 Redis: NoSQL key-value

In-memory data structure store, útil para base de datos de login-password, sensor-valor, URL-respuesta, con una sintaxis muy sencilla:

- El comando SET almacena valores
- SET server:name "luna"
- Recuperamos esos valores con GET
- GET server:name
- INCR incrementa atómicamente un valor
- INCR clients
- DEL elimina claves y sus valores asociados
- DEL clients
- TTL (Time To Live) útil para cachés
- EXPIRE promocion 60

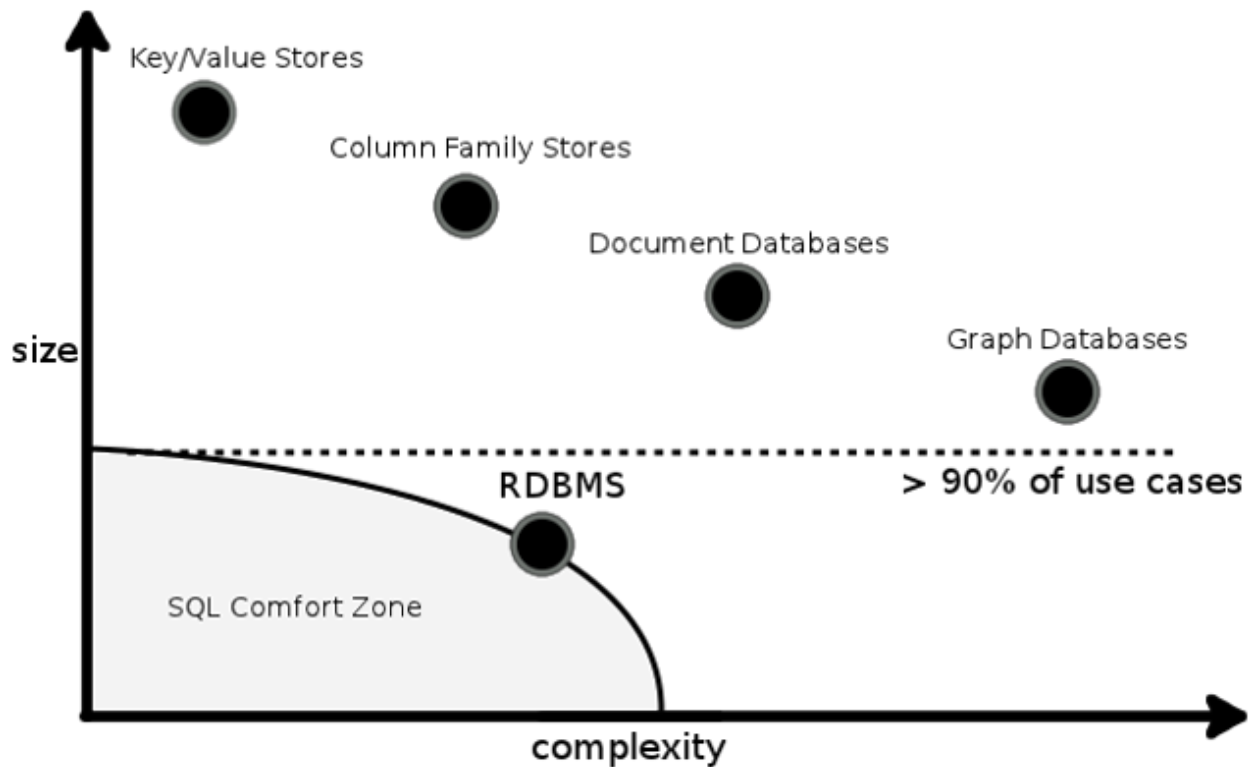


Figura 5.3:

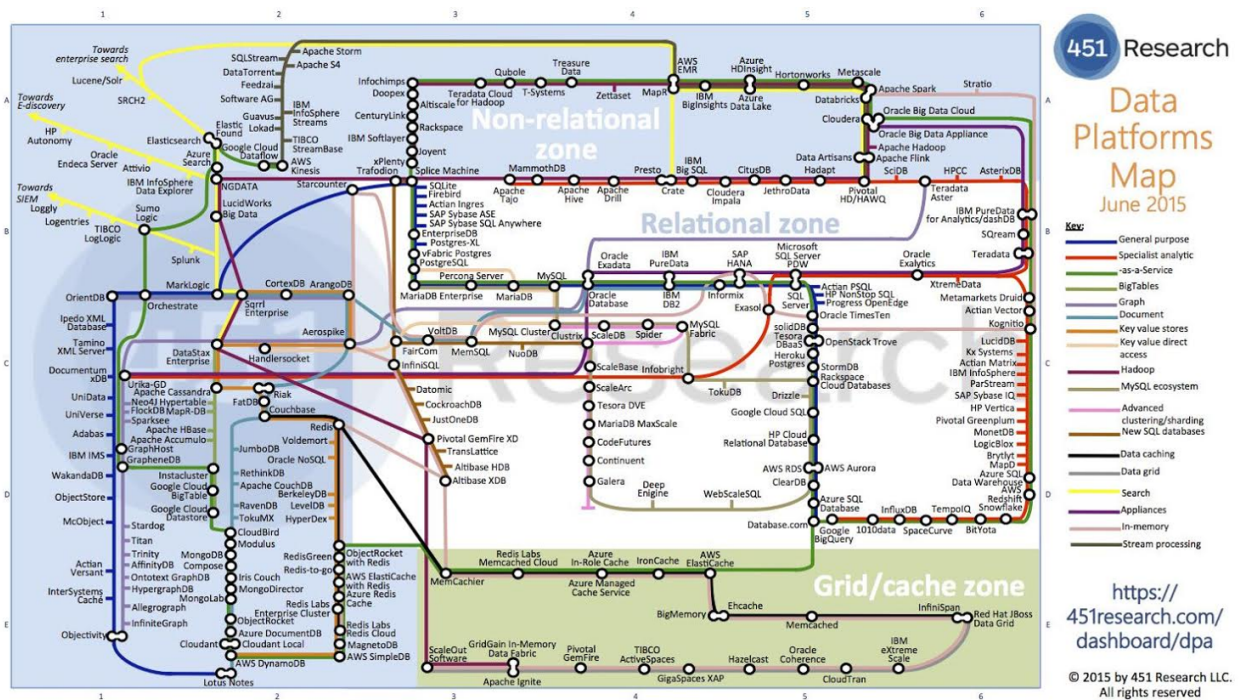


Figura 5.4:

5.1. CONCEPTOS Y TIPOS DE BASES DE DATOS NOSQL (DOCUMENTAL, COLUMNAR, CLAVE/VALOR Y DE GRAFOS)

352 systems in ranking, September 2019

Rank			DBMS	Database Model	Score		
Sep 2019	Aug 2019	Sep 2018			Sep 2019	Aug 2019	Sep 2018
1.	1.	1.	Oracle +	Relational, Multi-model ⓘ	1346.66	+7.18	+37.54
2.	2.	2.	MySQL +	Relational, Multi-model ⓘ	1279.07	+25.39	+98.60
3.	3.	3.	Microsoft SQL Server +	Relational, Multi-model ⓘ	1085.06	-8.12	+33.78
4.	4.	4.	PostgreSQL +	Relational, Multi-model ⓘ	482.25	+0.91	+75.82
5.	5.	5.	MongoDB +	Document	410.06	+5.50	+51.27
6.	6.	6.	IBM Db2 +	Relational, Multi-model ⓘ	171.56	-1.39	-9.50
7.	7.	7.	Elasticsearch +	Search engine, Multi-model ⓘ	149.27	+0.19	+6.67
8.	8.	8.	Redis +	Key-value, Multi-model ⓘ	141.90	-2.18	+0.96
9.	9.	9.	Microsoft Access	Relational	132.71	-2.63	-0.69
10.	10.	10.	Cassandra +	Wide column	123.40	-1.81	+3.85

Figura 5.5:




Figura 5.6:

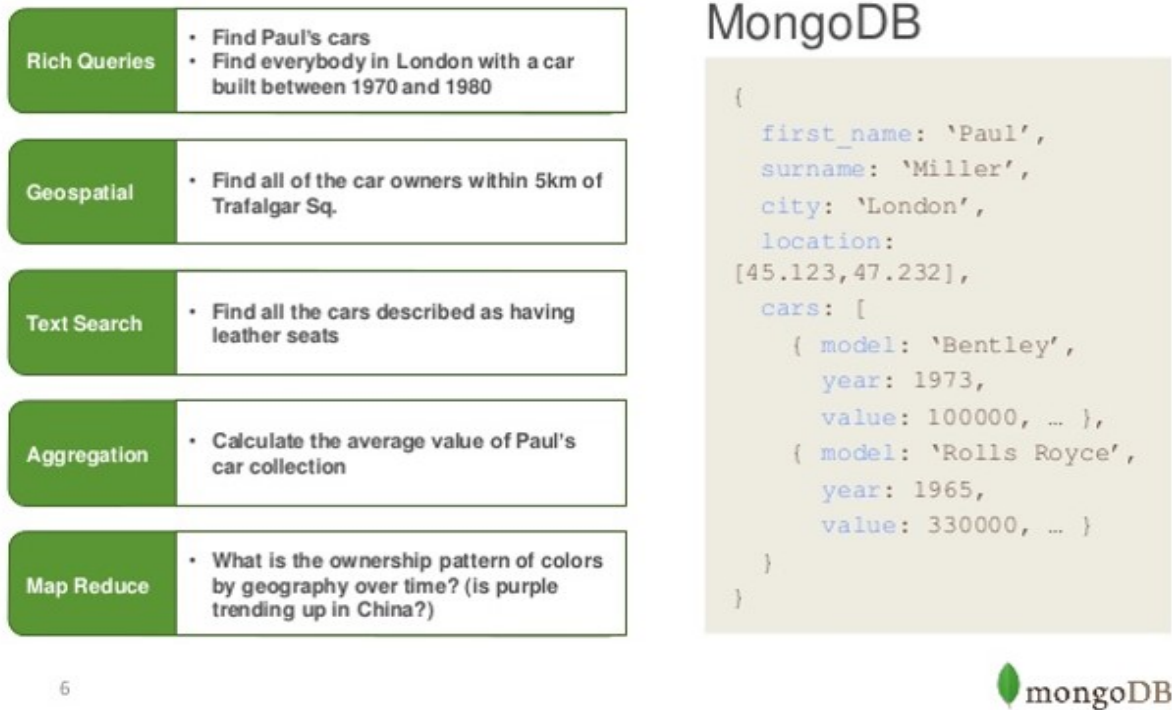


Figura 5.7:

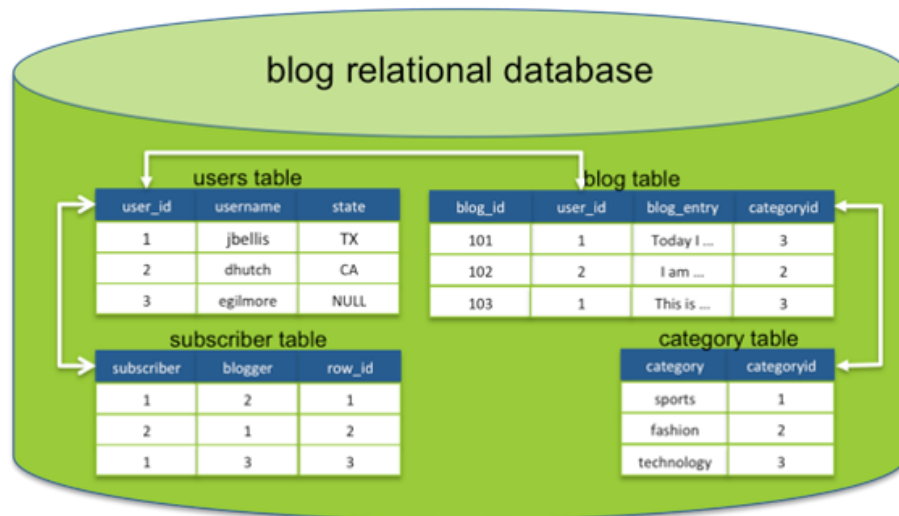


Figura 5.8:

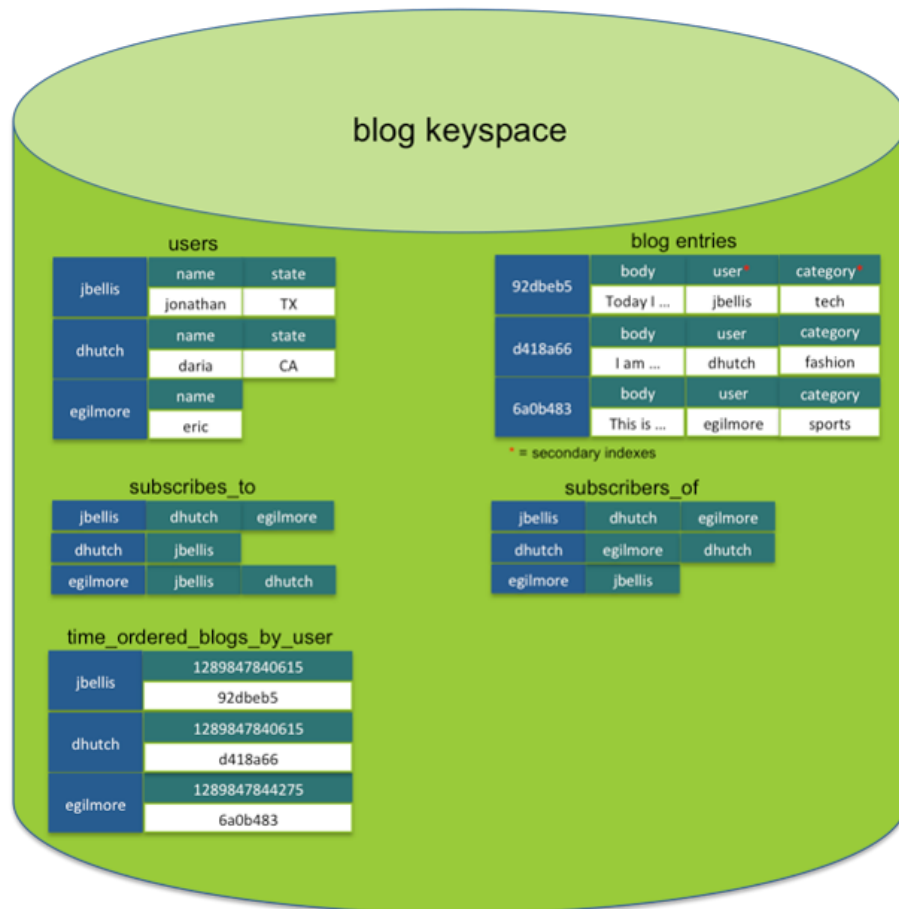



Figura 5.9:



Figura 5.10:



```
MATCH (john {name: 'John'})-[:friend]->()-[:friend]->(fof)
RETURN john, fof
```

Figura 5.11:

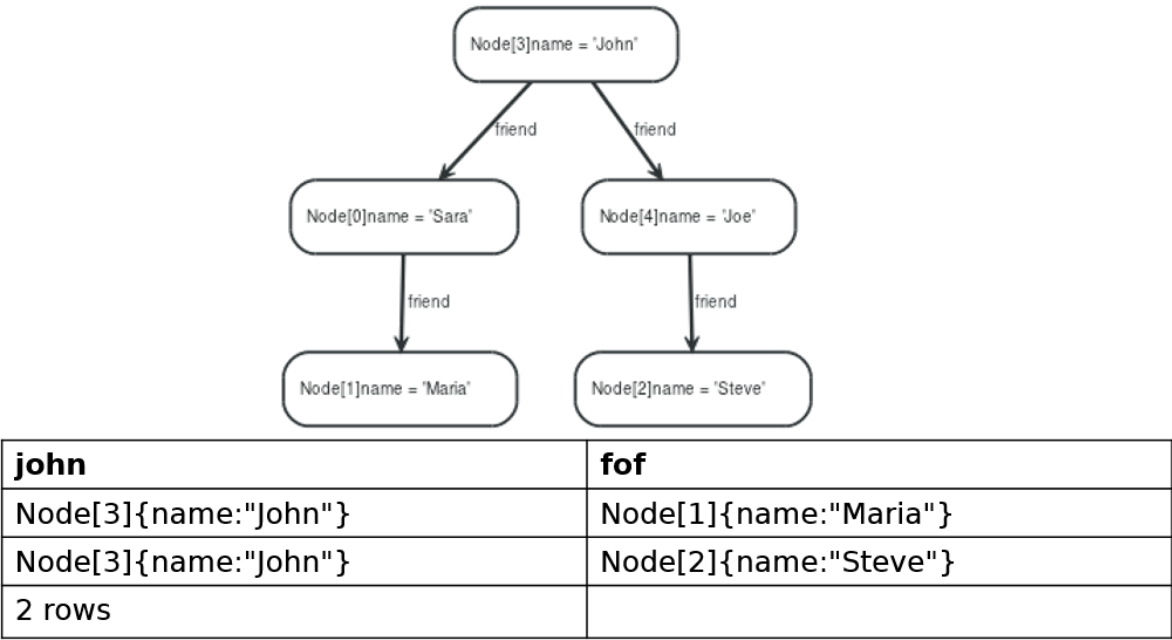


Figura 5.12:

5.1.5 Cassandra: NoSQL columnar

5.1.6 Neo4j: NoSQL grafos

5.1.7 Otros: search engines

Son sistemas especializados en búsquedas, procesamiento de lenguaje natural como ElasticSearch, Solr, Splunk (logs de aplicaciones), etc...

5.2 Conexión de R a NoSQL

Step1: Install Packages plyr,XML Step2: Take xml file url Step3: create XML Internal Document type object in R using xmlParse() Step4 :Convert xml object to list by using xmlToList() Step5: convert list object to data frame by using ldply(xl, data.frame)

```
install.packages("XML")
```

```
install.packages("plyr")
```


Capítulo 6

Tecnologías para el Tratamiento de Datos Masivos

6.1 Tecnologías Big Data (Hadoop, Spark, Hive, Rspark, Sparklyr)

Introducción a los conceptos básicos del ecosistema Hadoop

6.2 Visualización y Generación de Cuadros de Mando

6.3 Introducción al Análisis de Datos Masivos

Apéndice A

Enlaces

Recursos para el aprendizaje de R (<https://rubenfcasal.github.io/post/ayuda-y-recursos-para-el-aprendizaje-de-r>): A continuación se muestran algunos recursos que pueden ser útiles para el aprendizaje de R y la obtención de ayuda...

Ayuda online:

- Ayuda en línea sobre funciones o paquetes: RDocumentation
- Buscador RSeek
- StackOverflow

Cursos: algunos cursos gratuitos:

- Coursera:
 - Introducción a Data Science: Programación Estadística con R
 - Mastering Software Development in R
- DataCamp:
 - Introducción a R
- Stanford online:
 - Statistical Learning
- Curso UCA: Introducción a R, R-commander y shiny
- Udacity: Data Analysis with R
- Swirl Courses: se pueden hacer cursos desde el propio R con el paquete swirl.

Para información sobre cursos en castellano se puede recurrir a la web de R-Hispano en el apartado formación. Algunos de los cursos que aparecen en entradas antiguas son gratuitos. Ver: Cursos MOOC relacionados con R.

Libros

- ***Iniciación:***
 - R for Data Science (online, O'Reilly)
 - 2011 - The Art of R Programming. A Tour of Statistical Software Design, (No Starch Press)
 - Hands-On Programming with R: Write Your Own Functions and Simulations, by Garrett Grolemund (O'Reilly)

- **Avanzados:**
 - 2008 - Software for Data Analysis: Programming with R - Chambers (Springer)
 - Advanced R by Hadley Wickham (online: 1ª ed, 2ª ed, Chapman & Hall)
 - R packages by Hadley Wickham (online, O'Reilly)
- **Bookdown:** el paquete `bookdown` de R permite escribir libros empleando R Markdown y compartirlos. En <https://bookdown.org> está disponible una selección de libros escritos con este paquete (un listado más completo está disponible aquí). Algunos libros en este formato en castellano son:
 - Prácticas de Simulación (disponible en el repositorio de GitHub [rubenfcasal/simbook](#)).
 - Escritura de libros con bookdown (disponible en el repositorio de GitHub [rubenfcasal/bookdown_intro](#)).
 - R para profesionales de los datos: una introducción.
 - Estadística Básica Edulcorada.

Material online: en la web se puede encontrar mucho material adicional, por ejemplo:

- CRAN: Other R documentation
- Blogs en inglés:
 - <https://www.r-bloggers.com/>
 - <https://www.littlemissdata.com/blog/rstudioconf2019>
 - RStudio: <https://blog.rstudio.com>
 - Microsoft Revolutions: <https://blog.revolutionanalytics.com>
- Blogs en castellano:
 - <https://www.datanalytics.com>
 - <http://oscarperpinan.github.io/R>
 - <http://rubenfcasal.github.io>
- Listas de correo:
 - Listas de distribución de r-project.org: <https://stat.ethz.ch/mailman/listinfo>
 - Búsqueda en R-help: <http://r.789695.n4.nabble.com/R-help-f789696.html>
 - Búsqueda en R-help-es: <https://r-help-es.r-project.narkive.com>
<https://grokbase.com/g/r/r-help-es>
 - Archivos de R-help-es: <https://stat.ethz.ch/pipermail/r-help-es>

A.1 RStudio

RStudio:

- Online learning,
- Webinars,
- tidyverse,
- Databases using R, dplyr as a database interface,

- sparklyr,
- shiny,
- CheatSheets: rmarkdown, shiny, dplyr, tidyr, stringr.